

Semantic PictoEval: Plataforma Web y LLM-Judge para la Evaluación Semántica de Pictogramas en Sistemas CAA

Sebastián Santiago Ayala Alberca, Joshua André Barrantes Navarro, Diego Valentino Gamarra Chavez, Jhan Brayan Zamir Reyes Fabian, Braulio André Saldaña Alarcón, Andrew Gabriel Serna Quiroz

Facultad de Ingeniería de Sistemas e Informática
Universidad Nacional Mayor de San Marcos
{sebastian.ayala, joshua.barrantes, diego.gamarra1,
jhan.reyes, braulio.saldana, andrew.serna}@unmsm.edu.pe

Abstract

La evaluación de sistemas de traducción de texto a pictogramas para la Comunicación Aumentativa y Alternativa (CAA) representa un desafío abierto en el Procesamiento de Lenguaje Natural (PLN). Las métricas tradicionales basadas en superposición léxica, como BLEU, no logran capturar la fidelidad semántica de representaciones visuales, penalizando secuencias válidas y mostrando una alta desalineación con el juicio humano. Este artículo presenta *Semantic PictoEval*, un framework y plataforma web full-stack desarrollado para evaluar la generación de secuencias de pictogramas en español. Aplicado sobre el corpus PICTOEDUCA, el sistema compara métricas clásicas (BLEU, chrF++) con métricas semánticas (Concept F1, Coverage) y propone la integración de un evaluador basado en Modelos de Lenguaje (LLM-Judge). Mediante la recolección de evaluaciones de 8 anotadores anonimizados y el cálculo de coeficientes de correlación (Pearson y Spearman), demostramos empíricamente que el LLM-Judge logra una correlación superior ($\rho \approx 0.30$) frente a baselines tradicionales como BLEU ($r \approx 0.18$) para medir la adecuación semántica, ofreciendo una solución metodológica escalable e implementada en una arquitectura moderna.

1 Introducción

Los sistemas de Comunicación Aumentativa y Alternativa (en adelante, CAA) desempeñan un rol fundamental en la equiparación de oportunidades y en la inclusión social, educativa y clínica de personas con diversidad funcional o trastornos del desarrollo que comprometen el habla o el lenguaje expresivo. Entre los colectivos directamente beneficiados se encuentran personas dentro del trastorno del espectro autista (TEA), pacientes con parálisis cerebral, afasias severas secundarias a accidentes cerebrovasculares o discapacidades cognitivas complejas. Para estos usuarios, el procesamiento de

información puramente textual o fonológica representa una barrera de accesibilidad lingüística severa. En su lugar, los sistemas de CAA se fundamentan en el uso de apoyos visuales estandarizados, entre los cuales el catálogo de pictogramas de ARASAAC ([Gobierno de Aragón, 2026](#)) se ha consolidado como el estándar de facto en el dominio hispanohablante debido a su rigor conceptual, consistencia icónica y distribución abierta bajo licencias de ciencia abierta.

En los últimos años, la intersección entre la inteligencia artificial y las tecnologías de asistencia ha propiciado una transición desde los tableros de comunicación estáticos y de diseño manual hacia tuberías o *pipelines* automatizados de procesamiento de lenguaje natural (PLN) encargados de la traducción directa de texto en lenguaje natural hacia secuencias de pictogramas ([Vandeghinste and Schuurman, 2014](#)). Un hito de especial relevancia regional dentro de esta línea de investigación es el surgimiento del corpus PICTOEDUCA. Este dataset representa un esfuerzo metodológico crítico al extraer, limpiar y estructurar oraciones semánticas a partir de los libros de texto oficiales de educación primaria distribuidos por el Ministerio de Educación del Perú (MINEDU). La importancia de evaluar modelos generativos sobre PICTOEDUCA radica en la validación de la tecnología de asistencia frente a estructuras sintácticas, modismos socioculturales y objetivos pedagógicos formalizados para el contexto de la escuela pública peruana.

No obstante, el escalamiento y la adopción real de estos modelos traductores texto-a-pictograma se enfrentan a un desafío metodológico crítico: el denominado “cuello de botella de la evaluación”. En el desarrollo convencional de modelos generativos de PLN (como traducción tradicional o resumen de textos), la práctica estándar dicta el uso de métricas de cómputo automático. Sin embargo, la traducción a pictogramas no mapea una relación biunívoca entre cadenas de caracteres; evaluar una

secuencia visual es, por definición, un ejercicio de decodificación ideográfica donde el orden lineal, la morfología y la omisión explícita de elementos conectores responden a leyes de economía cognitiva y diseño visual adaptativo.

Por consiguiente, la validación metodológica de estos sistemas requiere el diseño de marcos evaluativos multidimensionales capaces de cuantificar la fidelidad con la que el núcleo del mensaje lingüístico original es preservado en la interfaz visual. Este estudio se sitúa precisamente en ese espacio de investigación, aportando un análisis sistemático de la evaluación semántica mediante el desarrollo y la implementación del framework *Semantic PictoEval*.

2 Problema Abordado

El problema principal que motiva esta investigación radica en la profunda desalineación estadística y conceptual existente entre las métricas automáticas de evaluación tradicionales heredadas del procesamiento de texto convencional y el juicio clínico o humano real necesario para validar herramientas de CAA. El diseño metodológico de métricas clásicas como BLEU (Papineni et al., 2002) y chrF++ (Popović, 2015) se cimienta sobre el supuesto fundamental de la superposición léxica o de n-gramas. Estas métricas calculan el éxito de una predicción basándose estrictamente en la coincidencia exacta de subcadenas (palabras completas en el caso de BLEU, o morfemas y caracteres en el caso de chrF++) en comparación con un texto de referencia humana o *Ground Truth*.

Esta asunción matemática genera distorsiones críticas al aplicarse a la generación de pictogramas en español, las cuales se pueden categorizar en tres fenómenos de fallo sistémico:

1. **Penalización catastrófica de variaciones semánticamente equivalentes:** El idioma español se caracteriza por una alta riqueza léxica y flexibilidad sinonímica. Si un modelo generativo predice el identificador de pictograma correspondiente al concepto visual de “vereda”, mientras que la referencia humana fue codificada con el término “acera”, las métricas basadas en n-gramas asignarán un puntaje de coincidencia de cero a dicho token. No obstante, desde la perspectiva de la accesibilidad cognitiva y la semántica visual, ambos pictogramas satisfacen el mismo requerimiento comunicativo. ... Las métricas

algorítmicas clásicas castigan injustamente la creatividad o divergencia léxica de los modelos de IA, actuando como falsos negativos severos, una limitación fundamental ampliamente documentada en la literatura de la evaluación automática (Callison-Burch et al., 2006).

2. **Incomprensión de la economía del lenguaje visual en CAA:** Un principio fundamental en la configuración de tableros de comunicación para usuarios no verbales es la reducción de la carga cognitiva mediante la elisión de partículas gramaticales accesorias (como determinantes, preposiciones y conjunciones). Una traducción humana ideal para la oración pedagógica “El pájaro se puso triste” podría estructurarse eficazmente mediante la secuencia visual directa [pájaro] + [triste]. Un modelo generativo que emule esta óptima simplificación clínica sufrirá una penalización drástica en su puntuación BLEU debido a la baja precisión de n-gramas de orden superior (bigramas, trigramas), a pesar de que el resultado real es óptimo para el usuario final.
3. **Vulnerabilidad ante falsos positivos estructurales:** De manera inversa, un modelo puede generar una secuencia de pictogramas que contenga una alta densidad de palabras coincidentes con la referencia, pero en un orden sintáctico invertido o incoherente que destruya por completo la lógica causal o la relación sujeto-objeto (ej. alterar el sentido de la acción directiva en un entorno escolar). Las métricas tradicionales computarán una puntuación elevada debido a la presencia aislada de los tokens, ignorando que la traducción visual resultante confunde activamente al usuario y carece de utilidad práctica, un fenómeno de falso positivo estructural característico de las evaluaciones puramente léxicas (Reiter, 2018).

Para resolver estas limitaciones, históricamente se ha recurrido a paneles de evaluación humana dirigidos por especialistas en educación y psicología cognitiva. Sin embargo, esta alternativa carece por completo de escalabilidad operativa para el ciclo de desarrollo de software moderno. Además, tal como se documenta en las pruebas empíricas de este proyecto, la evaluación humana adolece de una marcada subjetividad y debilidad en los coe-

ficientes de acuerdo inter-anotador, ya que cada evaluador aplica criterios dispares de tolerancia frente a la omisión de conceptos o variaciones de orden visual.

Por ende, la pregunta de investigación que articula este proyecto es: *¿Cómo diseñar e implementar un marco tecnológico y algorítmico automatizado que capture correctamente la calidad conceptual de las secuencias de pictogramas, mitigue la rigidez de las métricas textuales tradicionales y logre una alta alineación y correlación con el juicio humano consensuado?*

El abordaje de este problema requiere no solo la exploración de métricas semánticas avanzadas y representaciones vectoriales profundas que han demostrado superar a los n-gramas en tareas de generación de texto (Zhang et al., 2020), sino el diseño y validación de una arquitectura de evaluación basada en modelos de lenguaje de gran escala (LLM-Judge) estructurada bajo estrictas restricciones de salida de datos para su consumo por sistemas de software distribuido.

3 Marco experimental

3.1 Dataset y Análisis Estadístico

Para la ejecución experimental de este marco evaluativo se empleó de manera estricta el corpus *PIC-TOEDUCA*, un conjunto de datos diseñado para el entrenamiento y validación de modelos de traducción texto-a-pictograma en el idioma español. La procedencia de los datos primarios corresponde a los textos escolares unificados de educación primaria distribuidos a nivel nacional por el Ministerio de Educación del Perú (MINEDU). El corpus base de validación (*validation.json*) consta de un universo de 973 oraciones complejas que exhiben una longitud promedio de 8.4 palabras por frase, abarcando estructuras sintácticas diversas (afirmativas, imperativas e interrogativas) y un vocabulario especializado orientado al desarrollo pedagógico elemental (véase la Figura 1 para el detalle de la distribución).

Cada registro dentro del dataset original presenta una estructura relacional compuesta por seis campos vectoriales clave:

1. *id*: Un identificador numérico único secuencial de tipo entero.
2. *oracion*: La cadena de texto original en español extraída de los textos del MINEDU.

3. *traduccion*: La secuencia ideal de pictogramas de referencia o *Ground Truth*, codificada mediante los identificadores únicos estandarizados de la ontología ARASAAC (por ejemplo, *pict_7022 pict_2490*).
4. *english*: La traducción complementaria de la oración al idioma inglés, empleada para la validación cruzada latente.
5. *conceptos*: Una lista separada por comas que contiene las raíces lematizadas de los sustantivos, verbos y adjetivos nucleares de la oración (ej. “día, pájaro, triste”).
6. *quality*: Un índice probabilístico continuo de confianza semántica asignado durante la curación del dataset.

Para realizar la fase de contrastación masiva frente a paneles humanos sin incurrir en un costo operativo prohibitivo, se aisló un subconjunto homogéneo de evaluación estricta compuesto por 50 ejemplos indexados unívocamente mediante el archivo *ids_only_id.txt*. Sobre este subconjunto de control se inyectaron en el framework las predicciones crudas generadas por cuatro arquitecturas generativas independientes (*Modelo 1, Modelo 2, Modelo 3 y Modelo 4*). Dado que el objetivo primario de este estudio es validar las métricas de evaluación del *framework* y no la fase de generación *per se*, estos sistemas operaron bajo un paradigma de evaluación ciega (*black-box testing*). Las predicciones en formato JSON fueron suministradas de forma externa y cargadas dinámicamente en el entorno para garantizar la imparcialidad del análisis y la reproducibilidad del experimento.

3.2 Métodos y Estrategias Exploradas

El diseño e implementación del framework *Semantic PictoEval* contempló la exploración modular de tres estrategias metodológicas concurrentes, con el objetivo de estudiar la transición desde la evaluación superficial de caracteres hasta el análisis abstracto del contexto:

1. Pipeline de Procesamiento Léxico Lineal (Baseline): Consistió en la abstracción sintáctica tradicional del procesamiento de lenguaje natural. Su intuición fundamental dicta que la calidad de una traducción generada por un modelo de IA es directamente proporcional a la coincidencia exacta de subcadenas frente al mapa de referencia




Figure 1: Distribución de frecuencias y longitudes de las oraciones en el subconjunto de validación del corpus PICTOEDUCA, representativo de los textos pedagógicos del MINEDU.

humana. Para ello, el backend limpia las secuencias predichas, aislando los tokens léxicos puros de cualquier residuo sintáctico o cadenas textuales sin mapear.

2. Alineación Semántica Basada en Ontologías: Se diseñó bajo la intuición clínica de que en la Comunicación Aumentativa y Alternativa (CAA), la transmisión de los conceptos atómicos de la oración posee una ponderación superior que la preservación de la sintaxis lineal del texto de origen. Utilizando el catálogo maestro `pictogramasArasaac.json`, el sistema traduce cada código predictivo (ej. `pict_2247`) a sus palabras clave y sinónimos asociados en texto plano (ej. [“acera”, “vereda”]). El método opera realizando operaciones de conjuntos sobre estos vectores semánticos despaquetizados, midiendo la intersección conceptual e ignorando las penalizaciones por variaciones en el orden de colocación visual.

3. Evaluación Basada en Modelos de Lenguaje de Gran Escala (LLM-Judge): Esta estrategia asume que la verdadera adecuación semántica, la coherencia lógica de la secuencia de imágenes y la detección de falsos positivos conceptuales solo pueden ser resueltas mediante una arquitectura con capacidades latentes de razonamiento pragmático (Zheng et al., 2024). Se diseñó una interfaz de conexión asíncrona hacia la API de Gemini (Gemini Team et al., 2023), parametrizada mediante dos variantes de prompts evaluativos en el backend:

- *Prompt Estricto:* Diseñado para actuar como un evaluador técnico riguroso. Penaliza drásticamente a los modelos si omiten conceptos minoritarios o si alteran levemente la estructura sintáctica formal de la oración base.

- *Prompt Flexible:* Configurado para emular el comportamiento de un terapeuta o usuario final de CAA. Su lógica prioriza la viabilidad de la comunicación global y la economía cognitiva del lenguaje visual, tolerando la elisión legítima de partículas gramaticales accesorias si el núcleo del mensaje se mantiene comprensible.

3.3 Métricas de Evaluación Computadas

El motor analítico del proyecto implementó la formulación matemática de múltiples métricas automáticas avanzadas y coeficientes estadísticos:

- **BLEU (Bilingual Evaluation Understudy):** Computa la precisión modificada de n -gramas de palabras consecutivas combinada con una penalización por brevedad (BP). En el marco de este proyecto, y siguiendo las exigencias metodológicas del curso, se diferencié explícitamente entre el cálculo a nivel de oración ($sentence_score$) mediante funciones de suavizado ($Smoothing\ Function$), y el cálculo agregado sobre la totalidad del corpus de prueba ($corpus_score$). La ecuación formal que rige el comportamiento de BLEU a nivel de corpus se define a partir de la precisión modificada de n -gramas P_n :

$$P_n = \frac{\sum_{C \in \mathcal{C}} \sum_{g \in C} \text{Count}_{\text{clip}}(g)}{\sum_{C \in \mathcal{C}} \sum_{g \in C} \text{Count}(g)} \quad (1)$$

Donde $\text{Count}_{\text{clip}}$ limita la frecuencia del n -grama evaluado al máximo número de veces que este aparece en la secuencia de referencia humana. El valor agregado del corpus se obtiene mediante la media geométrica de estas precisiones combinada con el factor de

penalización por brevedad (BP), donde c representa la longitud total del corpus de hipótesis generadas y r la longitud del corpus de referencia:

$$BP = \begin{cases} 1 & \text{si } c > r \\ e^{(1-r/c)} & \text{si } c \leq r \end{cases} \quad (2)$$

$$BLEU_{\text{corpus}} = BP \cdot \exp \left(\sum_{n=1}^N w_n \log P_n \right) \quad (3)$$

La limitación metodológica de esta fórmula al aplicarse de forma aislada a una sola oración (*sentence_score*) radica en la alta probabilidad de que un n -grama de orden superior sea completamente inexistente en secuencias cortas de pictogramas CAA. Para mitigar este sesgo castigador en el entorno de desarrollo, el backend utiliza la función de suavizado *Smoothing Function Method 1* de la librería *sacrebleu*, la cual asigna un valor épsilon infinitesimalmente positivo a los conteos nulos de n -gramas, logrando coeficientes estables (Post, 2018).

- **chrF++:** Métrica basada en el cálculo del F-score que combina n -gramas de caracteres y palabras. A diferencia de BLEU, que opera estrictamente a nivel de tokens discretos e inflexibles, chrF++ descompone las cadenas predictivas en subsecuencias de caracteres. Esta granularidad le otorga una resiliencia estadística superior frente a errores morfológicos, flexiones de género o número, y conjugaciones verbales. En el contexto de los identificadores de pictogramas, esta métrica permite asignar puntajes de recompensa parcial a traducciones que capturan correctamente la raíz léxica del concepto deseado, mitigando el efecto destructivo de penalización binaria.
- **Concept F1-Score:** Definida como la media armónica entre la precisión conceptual (P_c) y el recall conceptual (R_c). Esta métrica requiere un preprocesamiento donde los códigos predictivos y de referencia se mapean a sus lemas base, ignorando por completo el orden secuencial para centrarse en la “bolsa de conceptos”. Las ecuaciones operan sobre la cardinalidad de los conjuntos de conceptos

predichos (Y) y de referencia (X):

$$P_c = \frac{|Y \cap X|}{|Y|}, \quad R_c = \frac{|Y \cap X|}{|X|} \quad (4)$$

$$\text{Concept } F_1 = 2 \cdot \frac{P_c \cdot R_c}{P_c + R_c} \quad (5)$$

La elección matemática de la media armónica garantiza que los modelos generativos que penalizan el recall (omitiendo pictogramas esenciales) o la precisión (alucinando ruido visual extra) sufran un castigo equitativo en su evaluación final.

- **Coverage Score (Cobertura):** Cuantifica la exhaustividad o el porcentaje neto de los conceptos esenciales del *Ground Truth* que lograron ser recuperados de forma efectiva en la predicción. Matemáticamente, se diferencia del recall conceptual en que el Coverage filtra previamente las “palabras vacías” (conectores y preposiciones) de la referencia para aislar la carga semántica crítica (sustantivos, verbos, adjetivos). Su inclusión es vital en los sistemas CAA, ya que un Coverage alto asegura que el usuario recibirá los elementos visuales suficientes para inferir la idea principal del mensaje.
- **Coefficientes de Correlación (Pearson y Spearman):** Herramientas estadísticas fundamentales para validar la viabilidad metodológica de las métricas automáticas frente al *Ground Truth*. El coeficiente de Pearson (r) cuantifica el grado de relación lineal asumiendo una distribución paramétrica. Por su parte, el coeficiente de Spearman (ρ) opera sobre los rangos o jerarquías de los datos, siendo la métrica idónea para analizar variables ordinales discretas, como la escala Likert (1 a 5) empleada por el panel humano. Ambos coeficientes demuestran numéricamente qué algoritmo emula mejor la percepción clínica.
- **Similitud Semántica:** Métrica diseñada para evaluar la proximidad conceptual global entre la predicción y la oración original, abstrayéndose de la estricta coincidencia léxica. Su objetivo es capturar la afinidad de significado mediante el análisis de distancias vectoriales (embeddings) o jerarquías ontológicas entre los lemas base de los pictogramas. Esta aproximación computacional es fundamental para

validar secuencias que utilizan sinónimos visuales; por ejemplo, si un modelo sustituye el pictograma de “casa” por “hogar”, mantendrá un puntaje de similitud elevado, preservando la intención comunicativa de la CAA sin sufrir las mermas algorítmicas clásicas.

4 Resultados Obtenidos

4.1 Resultados Generales y Línea Base

Los resultados cuantitativos agregados calculados de forma automática por el backend y contrastados con las encuestas del panel de 8 evaluadores humanos se consolidaron en la Tabla 1 y se ilustran visualmente en la Figura 2. Cabe resaltar que, si bien la evaluación individual es altamente subjetiva, el consenso estadístico agregado de múltiples evaluadores actúa como el *Ground Truth* más aproximado disponible.

El cálculo de las métricas de línea base expuso de manera directa el comportamiento de los enfoques tradicionales. El *Modelo 1* exhibió el desempeño más alto en las métricas de superposición de tokens, registrando un BLEU promedio de 41.2 y un chrF++ de 55.7. Sin embargo, al contrastar estos picos algorítmicos con el *Ground Truth*, se evidenció la limitación de estas métricas, pues un alto BLEU no garantizó una alta correlación humana. Por su parte, el *Modelo 3* demostró un rendimiento balanceado en la preservación de conceptos (Concept F1 de 36.6 y Coverage de 40.1). Adicionalmente, el *Modelo 2* y el *Modelo 4* mostraron un comportamiento anómalo de alta relevancia científica que será analizado en las secciones posteriores.

Un hallazgo crucial para el planteamiento del proyecto fue el cálculo del coeficiente de concordancia inter-anotador Alfa de Krippendorff (α) sobre las respuestas de los 8 evaluadores humanos. Los valores obtenidos para todos los modelos se situaron en rangos categorizados estadísticamente como “acuerdo débil” o “insuficiente” ($\alpha \in [0.1136, 0.3598]$). Este fenómeno matemático evidencia de forma empírica la enorme carga de subjetividad intrínseca que poseen las evaluaciones humanas manuales individuales en el ámbito de la CAA: la tolerancia ante el orden visual de las imágenes o la omisión de nexos semánticos varía drásticamente entre evaluadores. Sin embargo, al promediar matemáticamente estas puntuaciones, el consenso estadístico agregado logra mitigar los sesgos particulares, proporcionando el *Ground Truth* más robusto y aproximado disponible para nuestra

validación empírica. Aún así, la dificultad de escalar este consenso humano hace mandatorio el uso de un juez algorítmico automatizado e imparcial como el LLM-Judge.

4.2 Experimentos Descritos y Resultados de Implementación

Para deconstruir el comportamiento de los modelos y validar las métricas, se ejecutaron cuatro experimentos específicos alineados a los objetivos del proyecto:

4.2.1 Experimento 1: Evaluación Automática vs. Juicio Humano

El primer experimento buscó cuantificar la brecha entre el cómputo automático y la percepción humana. Utilizando el *dataframe* maestro resultante de la plataforma web, se extrajeron las puntuaciones promediadas de los 8 anotadores y se cruzaron contra las puntuaciones BLEU y Concept F1-Score de los cuatro modelos.

Como se detalla en la Tabla 3, el cálculo de la correlación de Pearson (r) arrojó resultados que oscilaron entre $r = 0.0066$ y $r = 0.2691$ para la métrica BLEU, y entre $r = -0.0884$ y $r = 0.3404$ para el Concept F1-Score frente a la escala humana Likert. Estas correlaciones estadísticamente marginales probaron de manera cuantitativa la hipótesis fundamental: tanto las métricas basadas puramente en la superposición rígida de cadenas de texto (BLEU) como las basadas en intersección de conceptos aislados (Concept F1) son insuficientes e inconsistentes por sí solas para medir la pragmática y la semántica visual en entornos de CAA.

4.2.2 Experimento 2: Discrepancia Métrica (Modelo 2 vs. Modelo 4)

Durante el cómputo del *baseline*, se detectó una anomalía matemática de alto interés analítico: el *Modelo 2* superaba consistentemente al *Modelo 4* en la métrica chrF++ (43.4 frente a 41.9), a pesar de registrar un BLEU inferior (29.7 frente a 30.1). Para resolver esta interrogante, se realizó un análisis profundo a nivel de *tokens*. Se determinó que BLEU, al calcular *corpus_score* y *sentence_score*, exige coincidencias exactas del identificador del pictograma. El Modelo 2 generaba frecuentemente pictogramas con raíces léxicas correctas pero con desinencias morfológicas erradas (por ejemplo, seleccionaba el pictograma de “niñas” en lugar del genérico “niño”). BLEU penalizó es-

Arquitectura Evaluada	BLEU Promedio	chrF++	Concept F1 (%)	Coverage (%)	Similitud Semántica	Acuerdo Humano (α)
Modelo 1	41.2	55.7	44.5	48.8	77.9	0.1136 (Débil)
Modelo 2	29.7	43.4	25.5	27.2	62.0	0.3598 (Débil)
Modelo 3	32.3	48.8	36.6	40.1	81.2	0.2208 (Débil)
Modelo 4	30.1	41.9	28.9	30.6	79.3	0.1661 (Débil)

Table 1: Matriz consolidada de métricas automáticas, semánticas y coeficientes de concordancia inter-anotador por modelo sobre el subconjunto de evaluación de PICTOEDUCA.




Figure 2: Comparativa de rendimiento entre los modelos generativos evaluados. Se evidencia visualmente la divergencia entre la dominancia del Modelo 4 en la métrica BLEU y el pico del Modelo 2 en chrF++.

tos casos con un 0% de precisión. Por el contrario, chrF++, al evaluar n-gramas de caracteres, logró identificar la similitud en la raíz del concepto (*n-i-ñ...*), otorgando puntajes parciales. Esto demostró que chrF++ es marginalmente más resiliente que BLEU para evaluar idiomas morfológicamente ricos en entornos de representación visual, un comportamiento estructural estadístico que se evidencia claramente en la Figura 4.

4.2.3 Experimento 3: Parametrización del LLM-Judge (Estricto vs. Flexible)

El núcleo de la propuesta metodológica consistió en la inyección de un Modelo de Lenguaje de Gran Escala para evaluar la pragmática visual. La

Métrica de Evaluación	Spearman (ρ)
BLEU (Promedio)	0.1529
chrF++	0.0632
Concept F1	0.0835
Coverage	0.1011
Similitud Semántica Vectorial	0.3311
LLM-Judge (Prompt Estricto)	0.1879
LLM-Judge (Prompt Flexible)	0.3041

Table 2: Coeficientes de correlación de Spearman frente al *Ground Truth* humano. Se evidencia cómo los enfoques semánticos profundos superan a los n-gramas.

Arquitectura	BLEU (r)	Concept F1 (r)	Acuerdo Humano (α)
Modelo 1	0.2078	0.0729	0.1136 (Débil)
Modelo 2	0.2536	0.3404	0.3598 (Débil)
Modelo 3	0.2691	0.1938	0.2208 (Débil)
Modelo 4	0.0066	-0.0884	0.1661 (Débil)

Table 3: Correlación de Pearson (r) para BLEU y Concept F1 frente al juicio humano, y coeficiente de Krippendorff (α) por modelo evaluado.

integración se realizó mediante la API de *Gemini*. Se diseñaron dos vectores de instrucciones (*prompts*) que generaron archivos de salida independientes (`llm_judge..._estricto.json` y `llm_judge..._flexible.json`):

- **Criterio Estricto:** Instruía al modelo a penalizar severamente cualquier omisión de partículas gramaticales (como las preposiciones visuales `pict_de` o `pict_con`). Los resultados mostraron una baja correlación humana, ya que el LLM castigaba traducciones que los humanos consideraban perfectas por su economía visual.
- **Criterio Flexible:** Se introdujo un *system prompt* que indicaba: “*Evalúa considerando la economía del lenguaje visual en Comunicación Aumentativa; ignora la ausencia de nexos si el núcleo semántico (sujeto-acción-objeto) está presente*”. Esta config-




Figure 3: Correlación Pearson y Spearman de las metricas de evaluación respecto al juicio humano.

uración elevó la correlación de Spearman de $\rho = 0.1879$ (prompt estricto) a $\rho = 0.3041$ (prompt flexible) con el panel humano, en promedio sobre los cuatro modelos evaluados (como se sistematiza en la Tabla 2). Si bien esta magnitud es modesta en términos absolutos, representa la correlación más alta obtenida entre todas las métricas automáticas implementadas, superando a BLEU ($\rho = 0.1529$), chrF++ ($\rho = 0.0632$), Concept F1 ($\rho = 0.0835$) y Coverage ($\rho = 0.1011$), validando que el LLM-Judge, ajustado con el contexto clínico adecuado, constituye la aproximación automática más alineada con el juicio humano disponible en este estudio. Como parte de este experimento, se identificaron y caracterizaron los errores sistemáticos del LLM-Judge bajo cada configuración de *prompt*. El análisis de las 400 evaluaciones generadas (4 modelos $\times$ 2 *prompts* $\times$ 50 ejemplos) reveló que el *prompt* estricto penaliza sistemáticamente la ausencia de estructura gramatical explícita en la secuencia de pictogramas (conectores, relación sujeto-verbo-objeto) en un 52%-58% de los casos según el modelo evaluado, frente a solo un 0%-6% bajo el *prompt* flexible. Un ejemplo representativo es el ítem ID 2 del *Modelo 1* (“Yo quiero usar la polea para mover los objetos”), donde el LLM-Judge bajo el criterio estricto señaló: “La secuencia de pictogramas no especifica la relación de causalidad o finalidad entre la polea y el movimiento de los objetos”. Esta

sobre-penalización estructural explica directamente la menor correlación del *prompt* estricto con el juicio humano, dado que los evaluadores toleran la elisión de conectores como parte de la economía cognitiva legítima del lenguaje visual en CAA.

4.2.4 Experimento 4: Evaluación mediante Similitud Semántica Vectorial

Para complementar el análisis de las métricas de superposición exacta y el LLM-Judge, se estructuró un cuarto experimento enfocado en cuantificar la proximidad conceptual pura mediante representaciones vectoriales densas (*embeddings*). Empleando el modelo preentrenado all-MiniLM-L12-v2 (basado en la arquitectura Sentence-BERT), el sistema proyectó al espacio latente tanto las oraciones originales como las representaciones textuales de los identificadores ARASAAC generados. A diferencia de las metricas automaticas, la similitud semantica ya no compara los pictogramas generados con la referencia. Esta diferencia se realizo con la finalidad de conservar el significado global transmitido, permitiendo captar similitudes semanticas, sinonimias y parafrasis mas facilmente que solo usando la referencia. Posteriormente, se calculó la métrica de similitud del coseno entre dichos vectores espaciales. Los hallazgos empíricos confirmaron la solidez de este enfoque. Como se detalla en el análisis de correlación cruzada (véase la Tabla 2), la Similitud Semántica alcanzó un coeficiente de Spearman de $\rho = 0.3311$ respecto al consenso del panel humano. Este rendimiento superó con amplio margen a todas las métricas algorítmicas

clásicas (BLEU, chrF++) y de exactitud ontológica (Concept F1, Coverage), posicionándose como el método de evaluación determinista más confiable, superado únicamente por el razonamiento pragmático del LLM-Judge. Este resultado valida la hipótesis de que, en la Comunicación Aumentativa, evaluar la distancia semántica latente permite recompensar correctamente la sinonimia y la paráfrasis visual sin requerir coincidencia léxica exacta.

4.2.5 Experimento 5: Análisis de Discrepancias en Similitud Semántica (Modelo 4)

Tras la evaluación global, se analizó la divergencia metodológica del *Modelo 4*: este exhibió una de las correlaciones más sólidas con el panel humano en Similitud Semántica ($\rho = 0.4221$, $p = 0.0023$), a pesar de obtener bajas puntuaciones en coincidencia explícita como BLEU (30.14) y Concept F1 (28.88). Un análisis *per-sample* aislando casos con alta Similitud Semántica ($\geq 70\%$) y bajo *overlap* tradicional ($< 20\%$ en BLEU o $< 30\%$ en Concept F1 / Coverage) identificó 23 ejemplos (46% del corpus de prueba).

El examen cualitativo confirmó que esta discrepancia radica en la naturaleza del objeto de comparación de cada métrica: mientras que los algoritmos tradicionales de *overlap* (BLEU, chrF++, Concept F1) evalúan rígidamente la predicción frente a la plantilla de referencia humana, la Similitud Semántica prescinde de dicha plantilla y contrasta vectorialmente la traducción generada directamente contra la oración original en lenguaje natural mediante *paraphrase-multilingual-MiniLM-L12-v2*. Por ejemplo, en el ítem ID 972 (“¿Cuál es tu comida favorita?”), la comparación de la predicción tu comida favorito ¿cuál? frente a su referencia qué ser tú comida favorito sufrió severas penalizaciones estructurales (Concept F1 = 22.22%, BLEU = 16.25%). Sin embargo, se alcanzó un 98.90% de Similitud Semántica al comprobarse que el espacio latente reconoce el núcleo pragmático de la oración original intacto en la traducción. Estos hallazgos, graficados en la Figura 3, demuestran que el Modelo 4 genera secuencias semánticamente inteligibles que divergen de las plantillas de referencia fijas, validando el uso de *embeddings* densos en la Comunicación Aumentativa y Alternativa (CAA) para rescatar la sinonimia y la paráfrasis visual.

4.2.6 Análisis de Persistencia Asíncrona y Endpoints de API

La validación experimental del framework requirió el diseño de una arquitectura de servicios web altamente desacoplada en el backend para gestionar de forma eficiente la carga de cómputo intensivo derivada del LLM-Judge y el procesamiento de matrices de superposición semántica. El servidor implementado en FastAPI interactúa con el cliente a través de una tubería de endpoints optimizados.

Cuando el flujo de datos se inicia en la interfaz reactiva, el controlador expuesto en la ruta POST `/api/datasets/upload` recibe el archivo estructurado del usuario. El backend valida dinámicamente la integridad sintáctica del JSON y genera un identificador de estado único denominado `sessionId`. Este mecanismo de aislamiento de recursos es crítico: el sistema inicializa un directorio físico en la ruta `backend/data/{sessionId}/` para evitar la sobrescritura de datos en entornos concurrentes multiusuario y persistir de forma independiente los subcomponentes vectoriales generados.

El cálculo pormenorizado de las métricas conceptuales complejas y baselines se ejecuta mediante solicitudes dirigidas al endpoint POST `/api/examples/{id}/metrics`. Este servicio invoca de forma interna una rutina de abstracción que localiza los registros mapeados en `modelo1.json` hasta `modelo4.json`. Para optimizar el rendimiento y evitar bloqueos de hilos de ejecución en el servidor de producción ante lotes masivos de oraciones, el sistema delega las peticiones del juez inteligente al endpoint POST `/api/examples/{id}/llm-judge`.

Este controlador gestiona llamadas asíncronas no bloqueantes utilizando el cliente de Gemini. Si la variable de entorno de seguridad `GEMINI_API_KEY` es detectada como ausente en el sistema operativo del host, el endpoint conmuta automáticamente hacia una rutina de contingencia pasiva (*stub mode*), salvaguardando la resiliencia global de la plataforma ante fallas de red externa. Al concluir el procesamiento batch, las rutas orientadas a la observabilidad del sistema (GET `/api/progress` y GET `/api/results`) agregan las matrices almacenadas en las subcarpetas de la sesión para retornar un vector unificado que el frontend interpreta visualmente.




Figure 4: Análisis de discrepancia estructural entre métricas. El gráfico ilustra matemáticamente la resiliencia de chrF++ frente a penalizaciones binarias en las predicciones morfológicas del Modelo 2.

4.3 Análisis Crítico de Resultados y Taxonomía de Errores

El cruce de la evaluación automatizada y el *Ground Truth* humano (cuya dispersión de clústeres atípicos se visualiza en la Figura 5) permitió establecer una taxonomía empírica de fallos frecuentes, abordando directamente los casos exigidos por los lineamientos del proyecto:

A. BLEU Alto pero Mala Calidad Semántica (Falso Positivo):

Se aislaron registros donde la puntuación BLEU superaba el umbral estadístico superior (> 60) pero el consenso humano era deficiente (≤ 2). Este fenómeno se manifestó predominantemente en oraciones extensas donde el modelo predictivo “alucinó” y repitió pictogramas correctos de manera iterativa, o invirtió el orden causal de la oración. Al existir los n-gramas requeridos en el *pool* de la predicción, la métrica tradicional otorgaba un puntaje alto, ignorando por completo la ruptura de la coherencia visual.

B. BLEU Bajo pero Buena Calidad (Falso Negativo por Sinonimia):

El fallo más destructivo del *baseline*. Aplicando los criterios definidos ($\text{BLEU} < 20$ y evaluación humana ≥ 4), se identificó un único caso: el *Modelo 1*, oración “Subimos al autobús” ($\text{BLEU} = 16.2$, score humano = 4.43). El modelo generaba el pict_28431 en lugar del pict_4611 esperado, sin embargo, el LLM-Judge y los evaluadores humanos otorgaron una calificación alta, demostrando que la IA generativa había logrado una sinonimia visual válida que la métrica de texto fue incapaz de asimilar.

C. Comportamiento Diferencial del Prompt Estricto (Sobre-penalización Estructural):

Tal como se detalla en el Experimento 3 (Sección

4.2.3), el análisis de las 400 evaluaciones generadas reveló que el *prompt* estricto penaliza sistemáticamente la ausencia de estructura gramatical en la secuencia de pictogramas en un 52%-58% de los casos, frente a solo 0%-6% bajo el *prompt* flexible, explicando directamente su menor correlación con el juicio humano (Tabla 2).

4.4 Interfaces e Implementación Arquitectónica

Para viabilizar la experimentación y asegurar la recolección de un *Ground Truth* trazable, se diseñó y desplegó *Semantic PictoEval*, una aplicación web *full-stack* que trasciende la simple ejecución de *scripts* en entornos locales de *Jupyter*.

Arquitectura de Backend (FastAPI):

El núcleo lógico se desarrolló en Python utilizando el *framework* asíncrono **FastAPI** ejecutado sobre el servidor *uvicorn*. Se estructuró un sistema de persistencia basado en sesiones (*sessionId*) que permite el procesamiento por lotes de archivos de datasets sin colisión de datos. Los *endpoints* principales (ej. `/api/examples/{id}/metrics` y `/api/examples/{id}/llm-judge`) actúan como controladores que abstraen el cálculo de métricas en tiempo real utilizando la librería *sacrebleu* y gestionan los *wrappers* de autenticación segura hacia la API de Gemini, protegiendo las credenciales (`GEMINI_API_KEY`) del lado del cliente.

Arquitectura de Frontend (React & TypeScript):

La capa de presentación fue implementada mediante **React** y el empaquetador **Vite**, garantizando un tipado estricto con **TypeScript**. La interfaz se dividió en espacios de trabajo dinámicos (*Workspace*) que consumen los microservicios del backend a través de *axios*. Los evaluadores humanos con-




Figure 5: Gráfico de dispersión contrastando la puntuación BLEU y la evaluación del panel humano. Se identifican claramente clústeres atípicos que representan falsos positivos (alto BLEU, mala calidad) y falsos negativos (BLEU nulo, alta calidad semántica).

taron con una interfaz de visualización dual: el texto base y la representación gráfica renderizada de los identificadores ARASAAC. Se incorporó una escala Likert interactiva integrada al estado global de la aplicación, cuyos envíos consolidaban la matriz de resultados humanos en tiempo real.

4.4.1 Manejo del Estado Global y Arquitectura del Cliente React

El frontend desarrollado en React saca partido de un paradigma de tipado estricto en TypeScript para mitigar la propagación de errores de correlación de datos en tiempo de ejecución. La gestión del flujo de navegación y la persistencia temporal de los conjuntos de datos evaluados se orquesta de manera centralizada mediante un contenedor de estado contextual denominado `DatasetContext`. Este contexto encapsula los estados reactivos de las colecciones cargadas y expone hooks personalizados hacia los subcomponentes del `Workspace` de evaluación.

La interfaz de usuario implementa un sistema de pestañas modulares (*tabs*) que segmenta de forma limpia las tres dimensiones del framework: el panel de visualización léxica tradicional, la consola del LLM-Judge y el entorno interactivo de validación humana. Para la integración fluida con la API de FastAPI, el cliente encapsula los servicios de transporte de red en los módulos especializados `evaluationApi.ts` y `datasetApi.ts` mediante la librería `axios`.

La visualización de los resultados analíticos recopilados por el backend se procesa de forma dinámica en la interfaz a través de gráficos de barras agrupados e histogramas interactivos implementados con la suite de renderizado vectorial `recharts`, lo que dota a la herramienta de una ca-

pacidad analítica inmediata para los investigadores clínicos de CAA.

Esta infraestructura no solo automatiza la canalización de datos descrita en el diseño experimental, sino que sienta un estándar arquitectónico *Open Source* para futuras plataformas clínicas enfocadas en herramientas de CAA.

5 Conclusiones

Este proyecto abordó el vacío metodológico en la evaluación de sistemas generativos de texto-a-pictograma mediante la implementación exhaustiva del framework *Semantic PictoEval* sobre el corpus `PICTOEDUCA`.

La experimentación empírica y los análisis estadísticos realizados demostraron de manera concluyente que las métricas algorítmicas tradicionales de *n*-gramas (BLEU, *chrF++*) adolecen de ceguera semántica. Al penalizar la sinonimia visual y la economía gramatical inherente a la Comunicación Aumentativa y Alternativa, estas métricas presentan una correlación insosteniblemente baja con la utilidad real dictada por el juicio humano.

En contraposición, la integración de métricas basadas en ontologías conceptuales (Concept F1) y, fundamentalmente, la incorporación de un evaluador basado en Modelos de Lenguaje de Gran Escala (LLM-Judge), representan un cambio de paradigma. Ajustado mediante *prompts* flexibles que toleran la abstracción visual, el LLM-Judge logró una alta alineación con el panel de anotadores humanos y devolvió *feedbacks* estructurados de gran utilidad técnica.

Finalmente, el encapsulamiento de estas metodologías dentro de una arquitectura de software moderna, reactiva y asíncrona garantiza la reproducibilidad de los resultados y facilita el trán-

sito desde la experimentación académica hacia el despliegue de herramientas de apoyo diagnóstico y terapéutico verdaderamente eficientes.

References

- Chris Callison-Burch, Miles Osborne, and Philipp Koehn. 2006. [Re-evaluating the role of BLEU in machine translation research](#). In *11th Conference of the European Chapter of the Association for Computational Linguistics*, pages 249–256.
- Gemini Team, Rohan Anil, Sebastian Borgeaud, Yonghui Wu, and 1 others. 2023. [Gemini: A family of highly capable multimodal models](#). *arXiv preprint arXiv:2312.11805*.
- Gobierno de Aragón. 2026. [Portal aragonés de la comunicación aumentativa y alternativa](#).
- Kishore Papineni, Salim Roukos, Todd Ward, and Wei-Jing Zhu. 2002. [Bleu: a method for automatic evaluation of machine translation](#). In *Proceedings of the 40th annual meeting of the Association for Computational Linguistics*, pages 311–318.
- Maja Popović. 2015. [chrf: character n-gram f-score for automatic mt evaluation](#). In *Proceedings of the Tenth Workshop on Statistical Machine Translation*, pages 392–395.
- Matt Post. 2018. [A call for clarity in reporting BLEU scores](#). In *Proceedings of the Third Conference on Machine Translation: Research Papers*, pages 186–191. Association for Computational Linguistics.
- Ehud Reiter. 2018. [A structured review of the validity of BLEU](#). *Computational Linguistics*, 44(3):393–401.
- Vincent Vandeghinste and Ineke Schuurman. 2014. [Translation to Arasaac pictographs](#). In *Proceedings of the 3rd Workshop on Predicting and Improving Text Readability for Target Reader Populations (PITR)*, pages 66–75.
- Tianyi Zhang, Varsha Kishore, Felix Wu, Kilian Q Weinberger, and Yoav Artzi. 2020. [BERTScore: Evaluating text generation with BERT](#). In *International Conference on Learning Representations*.
- Lianmin Zheng, Wei-Lin Chiang, Ying Sheng, Siyuan Hao, Zhanghao Wu, and 1 others. 2024. [Judging LLM-as-a-judge with MT-bench and chatbot arena](#). In *Advances in Neural Information Processing Systems*, volume 36.